Nama : Gerald Amadeo Passover Sutanto
NIM : 2802457740

1. [LO-3 – 20 Points] Review & Evaluation of Data Quality.

a. Summarize the main data quality issues identified during the Mid Project (UTS).

Pada dataset yang akan diolah, terdapat beberapa masalah. Masalah yang timbul adalah data yang memiliki nilai error, unknown, dan NaN, tipe data yang salah, dan missing values yang ada di setiap kolom.

b. Evaluate how effective your data wrangling process was in improving data quality.

Pada data-data yang memiliki masalah, kami melakukan 2 tindakan. Tindakan pertama adalah mengganti semua yang bermasalah menjadi 'UNKNOWN'. Jika data yang diberikan 'UNKNOWN' tidak memungkinkan, maka data akan dihapus demi menjaga konsistensi data.

Lalu pada bagian Total spent, digunakan rumus matematika (Total Spent = Quantity x Price Per Unit) agar mengurangi impact pada drop column.

c. Support your evaluation using appropriate indicators (e.g., reduction in missing values, improved consistency, reduced outliers).

```
print(f"Jumlah Data Final: {df_final.shape[0]} baris")
```

```
Jumlah Data Final: 9227 baris
```

```
df_final.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9227 entries, 0 to 9226
Data columns (total 12 columns):
 #   Column            Non-Null Count  Dtype  
---  ------            --------------  -----  
 0   Transaction ID    9227 non-null   object 
 1   Item              9227 non-null   object 
 2   Quantity          9227 non-null   float64
 3   Price Per Unit    9227 non-null   float64
 4   Total Spent       9227 non-null   float64
 5   Payment Method    9227 non-null   object 
 6   Location          9227 non-null   object 
 7   Transaction Date  9227 non-null   object 
 8   Month             9227 non-null   object 
 9   Day_of_Week       9227 non-null   object 
 10  Year              9227 non-null   int64  
 11  Month_Year        9227 non-null   object 
dtypes: float64(3), int64(1), object(8)
```

```python
# Cek apakah sudah benar" bersih
pd.DataFrame({
    "missing_values": df_final.isnull().sum(),
    "missing_values_percentage":  df_final.isnull().sum() / len(df_final) * 100,
    "duplicate_rows": df_final.duplicated().sum()
})
```

	missing_values	missing_values_percentage	duplicate_rows
Transaction ID	0	0.0	0
Item	0	0.0	0
Quantity	0	0.0	0
Price Per Unit	0	0.0	0
Total Spent	0	0.0	0
Payment Method	0	0.0	0
Location	0	0.0	0
Transaction Date	0	0.0	0
Month	0	0.0	0
Day_of_Week	0	0.0	0
Year	0	0.0	0
Month_Year	0	0.0	0

```python
# Pengecekan values dari masing" Category
print(df_final['Location'].unique())
print(df_final['Payment Method'].unique())
print(df_final['Item'].unique())
```

```
['Takeaway' 'In Store' 'Unknown']
['Credit Card' 'Cash' 'Unknown' 'Digital Wallet']
['Coffee' 'Cake' 'Cookie' 'Salad' 'Smoothie' 'Sandwich' 'Juice' 'Tea']
```

2. [LO-2 – 30 Points] Advanced Pattern, Trend, and Relationship Analysis.

a. Extend your exploratory analysis by examining deeper or more specific relationships between variables (e.g., segmented analysis, time-based trends, subgroup comparison).

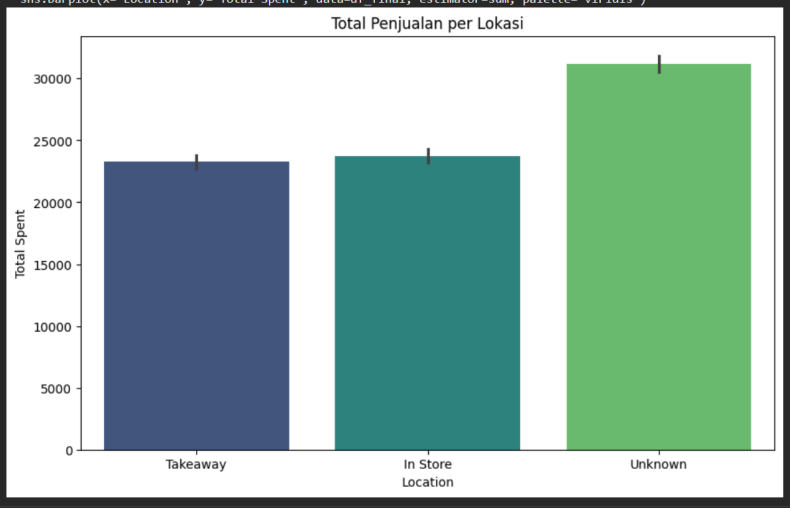
1. In-store vs Takeaway trend
   Kami menganalisa perbandingan sales yang terjadi di In-store dan Takeaway. Takeaway condong memiliki jumlah sales yang lebih banyak dari In-store, namun dalam dataset ini masih terdapat banyak sekali sales yang UNKNOWN.

```
# Apakah lokasi tertentu belanja lebih banyak?
plt.figure(figsize=(10, 6))
sns.barplot(x='Location', y='Total Spent', data=df_final, estimator=sum, palette='viridis')
plt.title('Total Penjualan per Lokasi')
plt.xticks()
plt.show()
```

```
/tmp/ipykernel_5578/3944394979.py:3: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.barplot(x='Location', y='Total Spent', data=df_final, estimator=sum, palette='viridis')
```



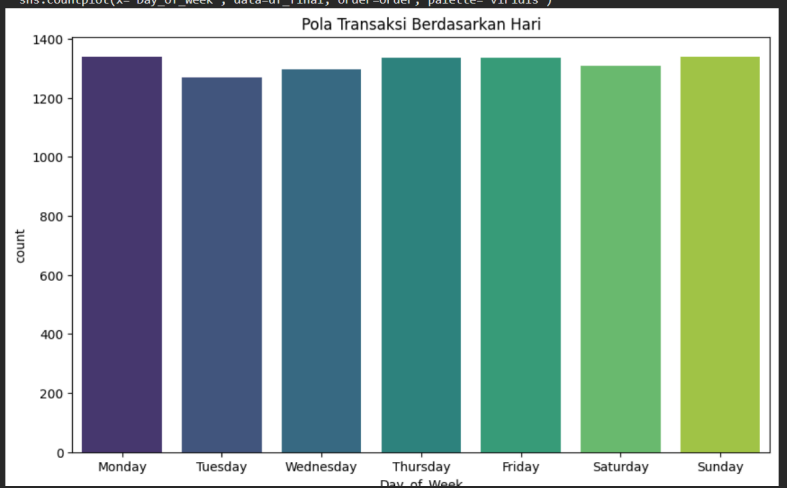
2. Pola per hari dalam seminggu
   Kami ingin menganalisa hari yang cenderung memiliki tingkat sales yang banyak.

```
# Patterns
# Hari apa yang paling ramai (untuk strategi restocking / penentuan jumlah karyawan)
plt.figure(figsize=(10, 6))
order = ['Monday', 'Tuesday', 'Wednesday', 'Thursday', 'Friday', 'Saturday', 'Sunday']
sns.countplot(x='Day_of_Week', data=df_final, order=order, palette='viridis')
plt.title('Pola Transaksi Berdasarkan Hari')
plt.show()
```

```
/tmp/ipykernel_5578/344190463.py:5: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.countplot(x='Day_of_Week', data=df_final, order=order, palette='viridis')
```



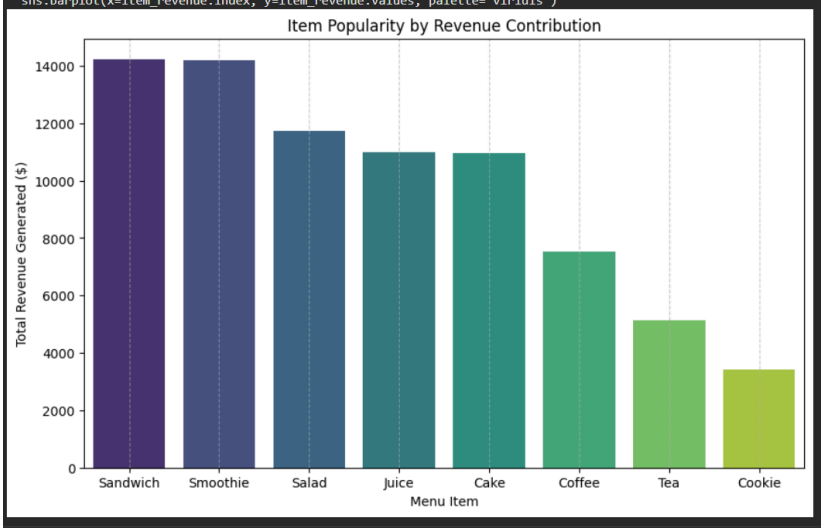
3. Revenue per item
   Kami memperlihatkan sales per item yang ada di store.

```python
# Item's Popularity by Revenue
item_revenue = df_final.groupby('Item')['Total Spent'].sum().sort_values(ascending=False)
plt.figure(figsize=(10, 6))
sns.barplot(x=item_revenue.index, y=item_revenue.values, palette='viridis')
plt.title('Item Popularity by Revenue Contribution')
plt.xlabel('Menu Item')
plt.ylabel('Total Revenue Generated ($)')
plt.grid(axis='x', linestyle='--', alpha=0.6)
plt.show()
```

```
/tmp/ipykernel_5578/2830955341.py:4: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.barplot(x=item_revenue.index, y=item_revenue.values, palette='viridis')
```



b. Identify the most influential variables related to the problem context.

Variabel yang paling berdampak pada analisa ini adalah Quantity, Price per Unit dan Total spent. Dan data yang paling berdampak adalah Item, karena dari data tersebut dapat disimpulkan ke banyak hal seperti sales per hari dan lainnya.

c. Explain why these relationships are meaningful using analytical evidence.

- Rolling Trend menunjukkan siklus mingguan, sehingga approach yang digunakan adalah prediksi secara harian.

- T-test p-value = 0.1137 menunjukkan perbandingan In-store dan takeaway tidak memiliki perbedaan sales yang signifikan, sehingga tidak perlu membuat strategi promosi atau operasional yang berbeda antara keduanya. Satu strategi cukup untuk kedua segmen.

```
Mean Total Spent for In Store: $8.57
Mean Total Spent for Takeaway: $8.33

Independent t-test results:
T-statistic: 1.58
P-value: 0.1137

Conclusion: Since the p-value (0.1137) is greater than the significance level (0.05), we fail to reject the null hypothesis.
There is no statistically significant difference in the mean Total Spent between 'In Store' and 'Takeaway' locations.
```

3. [LO-3 – 20 Points] Evaluation of Analytical Methods and Metrics

a. Describe the analytical techniques or models used in your project (e.g., correlation analysis, statistical comparison, simple predictive or scoring approach if applicable).

Teknik yang digunakan:

- EDA dengan visualisasi (heatmap, boxplot, line chart trend)

- Independent T-test untuk uji hipotesis In-Store vs Takeaway
- Random Forest Regressor dengan sliding window 14 hari untuk forecasting

b. Select and explain appropriate performance or evaluation metrics used to assess the effectiveness of your analysis (e.g., strength of correlation, error measures, distribution comparison, robustness checks).

Metrik	Sebelum Tuning	Setelah Tuning
MAE	34.62	35.33
MAPE	0.18 (18%)	0.18 (18%)
R^2 Score	0.09	0.07

c. Discuss the limitations of your analysis or models based on these metrics.

Dengan hasil R^2 Score yang hanya mencapai 0.09 berarti model hanya dapat menjelaskan 9% dari data aktual.
Data penjualan harian kafe kemungkinan sangat acak. Dan hyperparameter tuning yang sudah dilakukan dapat menurunkan R^2 score. Bukan parameternya yang bermasalah, melainkan informasi penting yang kurang.

4. [LO-4– 30 Points] Exploratory Data Analysis (EDA)

a. Propose 1–2 actionable recommendations based on your insights.

Rekomendasi saya:

1. Bagi jadwal produksi menjadi tiga tier: High(Sandwich, Smoothie, Salad), Medium(Cake, Juice, Coffee, Tea), Low(Cookie). Hal ini dapat menjawab salah satu business goal: mengurangi overstock dan stockout.
2. Membuat paket bundling. Jika dibuatkan paket dengan isi Coffee dan Sandwich kemungkinan dapat meningkatkan Average Transaction Value tanpa menambah beban operasional besar.

b. Explain how these recommendations could support decision making for relevant stakeholders.

- Manager operasional – Jadwal restocking lebih teratur dan presisi.
- Tim marketing – dasar pengambilan keputusan promosi berbasis data
- Pemilik – optimasi cost of goods sold

c. Discuss potential risks or considerations if the recommendations are implemented

- Risiko forecast accuracy – Dengan R^2 score yang masih rendah, model tidak bisa memberikan prediksi yang aman untuk digunakan.
- Risiko data UNKNOWN – Data masih memiliki value UNKNOWN yang memakan porsi besar sehingga membuat model tidak maksimal.